

SISTEMAS INTELIGENTES DISTRIBUIDOS (SID)

Práctica 2

Aprendizaje por refuerzo en el entorno Frozen Lake

Autores

Gabriel Alegre

Àngel Domínguez

Jesús Peñaranda

Índice

1. Value Iteration	1
1.1. Análisis	1
1.1.1. Experimento 1	1
1.1.2. Experimento 2	2
1.1.3. Experimento 3	3
1.1.4. Experimento 4	4
1.1.5. Experimento 5	5
2. Estimación Directa	6
2.1. Análisis	6
2.1.1. Experimento 1	6
2.1.2. Experimento 2	7
2.1.3. Experimento 3	8
2.1.4. Experimento 4	9
2.1.5. Experimento 5	10
2.1.6. Experimento 6	11
3. Q-Learning	12
3.1. Análisis	13
3.1.1. Experimento 1	13
3.1.2. Experimento 2	14
3.1.3. Experimento 3	15
3.1.4. Experimento 4	16
4. Conclusiones	18
4.1. Efecto del success rate	18
4.2. Efecto del factor de descuento (gamma)	18
4.3. Efecto sobre la escalabilidad al mapa 8x8	18
4.4. Efecto sobre la función de recompensa	19
4.5. Efecto sobre el tiempo de entrenamiento	19
4.6. Conclusión final	19

1. Value Iteration

El algoritmo por iteración de valor es un algoritmo de aprendizaje por refuerzo que permite obtener la política óptima de un entorno modelado como un Proceso de Decisión de Markov (MDP). Para calcular el valor esperado en cada estado iterativamente se usa la ecuación de Bellman:

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V_k(s')] . \quad (1)$$

La principal ventaja de Iteración de Valor es que garantiza la convergencia a la política óptima siempre que el entorno sea finito y completamente conocido. Sin embargo, su coste computacional aumenta considerablemente a medida que crece el espacio de estados.

1.1. Análisis

1.1.1. Experimento 1

Se ha planteado la siguiente hipótesis:

- **Relación con la estocasticidad:** esperamos que a medida que la variable *Success Rate* del entorno aumente (el suelo resbala en mayor cantidad), las iteraciones para converger disminuyan porque las acciones del agente son menos aleatorias.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8 (16 y 64 casillas) por el número necesario de acciones totales, pero se comportan de manera similar.




Figura 1: Gráfico que relaciona el número de iteraciones con la probabilidad de transición del algoritmo de iteración de valor.

Análisis de los resultados:

En la figura 1 se muestra la relación entre el número de iteraciones necesarias para converger y la probabilidad de transición (*success rate*) del algoritmo. Se observa que, a medida que aumenta el *success rate*, el número de iteraciones necesarias para converger disminuye, como habíamos previsto. Esto se debe a que un entorno menos estocástico permite que las acciones del agente tengan efectos más predecibles, lo que facilita el cálculo de la política óptima.

Además, aunque la evolución es similar en los mapas 4x4 y 8x8, el entorno 8x8 requiere un mayor número de iteraciones debido a su mayor complejidad y espacio de estados, pero como habíamos previsto la evolución de la probabilidad de transición es muy similar.

1.1.2. Experimento 2

Se ha planteado la siguiente hipótesis:

- **Relación con la estocasticidad:** esperamos que a medida que la variable *Success Rate* del entorno aumente, la tasa de éxito también aumente ya que las acciones son menos aleatorias.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8 (16 y 64 casillas), porque este último es más complejo, pero también se comportarán de manera similar.




Figura 2: Gráfico que relaciona la probabilidad de transición y la tasa de éxito del agente del algoritmo de iteración de valor.

Análisis de los resultados:

En la figura 2 puede observarse que, cuanto más cercano es el *success rate* a 1, mayor es la tasa de éxito obtenida por el agente. Esto ocurre porque aumenta la probabilidad de ejecutar correctamente la acción seleccionada y, en consecuencia, disminuye la aleatoriedad del entorno. De esta forma, la política calculada puede seguirse de manera más precisa y consistente.

Sin embargo, también se aprecia un comportamiento interesante que no habíamos tenido en cuenta cuando el *success rate* disminuye por debajo de 0.5. En ese intervalo, la tasa de éxito

vuelve a aumentar ligeramente, aunque sin alcanzar los valores obtenidos para probabilidades altas. Este fenómeno se explica por la dinámica estocástica del entorno.

Cuando el *success rate* se encuentra alrededor de 0.5, las probabilidades de avanzar en la dirección deseada o resbalar hacia una dirección perpendicular son muy similares, lo que genera un comportamiento altamente impredecible. En cambio, con valores inferiores a 0.5, el agente asume que es más probable deslizarse hacia una de las direcciones laterales que avanzar correctamente. Como consecuencia, la política óptima cambia y adopta una estrategia más conservadora, aprovechando esas transiciones laterales como parte principal del movimiento esperado. Esto permite recuperar parcialmente la tasa de éxito incluso en entornos con una elevada estocasticidad.

Además, puede observarse que el mapa de 4x4 obtiene mejores resultados que el de 8x8 en prácticamente todos los casos. Esto se debe a que, al aumentar el tamaño del entorno, también crece la complejidad del problema y el número de estados a recorrer, haciendo más difícil alcanzar la meta sin caer en agujeros o desviarse de la trayectoria óptima.

1.1.3. Experimento 3

Se ha planteado la siguiente hipótesis:

- **Relación con el factor de descuento:** esperamos que a medida que la Gamma aumente también lo haga la tasa de éxito para dar importancia a la recompensa del objetivo, el cual está relativamente lejos, pero siempre con valores menores que 1 para garantizar convergencia.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8, pero en el mapa 8x8 un factor de descuento más adecuado tendrá mejores resultados comparados con uno peor, ya que la recompensa del objetivo está más lejos.




Figura 3: Gráfico que relaciona la tasa de éxito con el factor de descuento del algoritmo de iteración de valor.

Análisis de los resultados:

En la figura 3, como es de esperar con $\text{Gamma} = 0$, la tasa de éxito es también 0 debido a que no tiene en cuenta las recompensas futuras y, por lo tanto, solo se guía por la recompensa inmediata del siguiente estado.

Cuanto más grande es el valor de Gamma , mejor tasa de éxito se obtiene, debido a que tiene más en cuenta la recompensa futura. También hay una diferencia clara entre los dos tipos de mapas, ya que los 8x8 son más complejos que los 4x4.

1.1.4. Experimento 4

Se ha planteado la siguiente hipótesis:

- **Relación con la estocasticidad:** esperamos que al aumentar el *success rate* el tiempo de entrenamiento para converger también disminuya porque las acciones son menos aleatorias.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8, y se comportarán de manera similar. Puede que en el mapa más pequeño se noten menos los cambios que en el mapa más grande porque los cambios afectarán más a entornos más complejos.




Figura 4: Gráfico que relaciona el tiempo de entrenamiento con la probabilidad de transición del algoritmo de iteración de valor.

Análisis de los resultados:

En la figura 4, la diferencia más evidente es que el mapa de 8x8 (naranja) consume significativamente más tiempo de entrenamiento que el de 4x4 (azul), como habíamos previsto. Esto se debe a que la complejidad computacional es mayor al cuadruplicar el número de estados, y el tiempo necesario para que los valores converjan aumenta de forma no lineal.

A medida que el *success rate* aumenta, el tiempo de entrenamiento tiende a disminuir y a estabilizarse, mostrando valores más consistentes entre ejecuciones. Esto se debe a que, con un *success rate* bajo, el entorno es más estocástico y el agente depende en mayor medida del azar.

para alcanzar determinados estados. En cambio, cuando el *success rate* es elevado, las acciones producen resultados más predecibles, lo que facilita el aprendizaje y permite una convergencia más rápida y estable.

1.1.5. Experimento 5

Se ha planteado la siguiente hipótesis:

- **Relación con la señal de recompensa:** esperamos que la tasa de éxito aumente si aumenta la señal de recompensa hasta cierto punto, desde el cual se mantendrá constante debido a que no hay otras recompensas que influyan.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8 por el aumento de complejidad, y se comportarán de manera similar.




Figura 5: Gráfico que relaciona la tasa de éxito con la señal de recompensa al llegar al objetivo del algoritmo de iteración de valor.

Análisis de los resultados:

En el mapa 4x4, la tasa de éxito se mantiene prácticamente constante alrededor del 43 %, independientemente de la recompensa final, lo cual no habíamos podido predecir. Esto ocurre porque el algoritmo de iteración de valor encuentra rápidamente la política óptima en un entorno relativamente pequeño.

En cambio, en el mapa 8x8 sí se aprecia una mejora progresiva a medida que aumenta la recompensa de la meta. Esto sí que se corresponde con lo que habíamos hipotetizado. En entornos más grandes y complejos, una recompensa final mayor incentiva al agente a asumir trayectorias más largas o arriesgadas para alcanzar el objetivo, aumentando la tasa de éxito. Sin embargo, la mejora termina estabilizándose cerca del 37 %, lo que indica que la estocasticidad del entorno continúa limitando el rendimiento del agente incluso con recompensas elevadas.

Por último, se observa que el mapa 8x8 obtiene peores resultados que el 4x4 en todos los casos. Esto se debe al incremento del espacio de estados y a que los errores producidos por el *slippery* tienen un impacto mucho mayor en trayectorias largas.

2. Estimación Directa

Este algoritmo se basa en aprender el valor de los estados o acciones a partir de la experiencia obtenida al ejecutar episodios completos en el entorno. Tras finalizar cada episodio, el algoritmo calcula el retorno acumulado desde cada estado visitado y actualiza su estimación utilizando el promedio de los resultados observados.

El valor de un estado se estima mediante:

$$V(s) = \frac{1}{N(s)} \sum_{i=1}^{N(s)} G_i(s). \quad (2)$$

A diferencia de la iteración de valor, la estimación directa no necesita conocer las probabilidades de transición del entorno ni su modelo interno. Su principal ventaja es la simplicidad y la capacidad de aplicarse a entornos donde no existe un MDP. No obstante, requiere de muchos episodios para obtener estimaciones precisas y suele presentar problemas de convergencia.

2.1. Análisis

2.1.1. Experimento 1

Se ha planteado la siguiente hipótesis:

- **Relación con la estocasticidad:** esperamos que las iteraciones para converger disminuyan al aumentar la probabilidad de transición ya que las acciones son menos aleatorias.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8, y se comportarán de manera similar.
- **Factor de descuento:** para mayores factores de descuento el agente se comportará mejor y tardará más iteraciones en converger, ya que detecta la recompensa del objetivo y la diferencia entre iteraciones es mayor.




Figura 6: Gráfico que relaciona el número de iteraciones con la probabilidad de transición del algoritmo de estimación directa.

Análisis de los resultados:

A diferencia de la iteración de valor, los resultados presentan una variabilidad mucho mayor, y no lo habíamos tenido en cuenta en la hipótesis. Esto se debe a que la estimación directa aprende únicamente a partir de episodios generados por experiencia, por lo que depende mucho del azar y de las trayectorias obtenidas durante el entrenamiento. En consecuencia, el número de iteraciones necesarias para converger en este algoritmo no sigue una tendencia tan estable.

Se puede observar en la gráfica que para valores altos del factor de descuento se necesitan más iteraciones para converger. Esto era predecible, puesto que lo que ocurre es que el algoritmo da más importancia a recompensas futuras, lo que aumenta la complejidad del aprendizaje, dado que las estimaciones dependen de trayectorias más largas.

Además, en el mapa 8x8 se nota más inestabilidad que en el mapa 4x4. Esto es debido a que el número de estados es mayor en entornos más grandes, lo que provoca que las probabilidades de desviarse sean mayores y, a la vez, dificulta obtener estimaciones precisas.

Respecto al *success rate*, aunque en algunos casos se nota una ligera mejora para un valor más alto, la mejora no es tan clara como en iteración de valor por el mismo motivo. El método de estimación directa continúa dependiendo de muestras aleatorias.

2.1.2. Experimento 2

Se ha planteado la siguiente hipótesis:

- **Relación con la estocasticidad:** esperamos que al aumentar el *success rate* aumente la tasa de éxito del agente. Además, sucederá el mismo efecto que con la gráfica de la iteración de valor que no tuvimos en cuenta: para valores muy pequeños funcionará mejor que para valores medios.
- **Escalabilidad del tamaño:** el mapa 4x4 presentará mejores resultados que el mapa con tamaño 8x8.

- **Factor de descuento:** para mayores factores de descuento el agente se comportará mejor y aumentará la tasa de éxito.




Figura 7: Gráfico que relaciona la tasa de éxito con la probabilidad de transición del algoritmo de estimación directa.

Análisis de los resultados:

En la figura 7 se observa, en general, que la tasa de éxito tiende a aumentar a medida que el *success rate* es mayor. Resulta coherente, ya que un entorno menos estocástico permite que las acciones ejecutadas por el agente produzcan resultados más predecibles, facilitando alcanzar la meta.

No obstante, se puede observar un comportamiento parecido a la misma gráfica pero con el algoritmo de iteración de valor como habíamos predicho: tiene una tendencia descendente en los valores medios del *success rate* y vuelve a subir. De hecho, esto se debe al mismo motivo por el que el agente con valores muy bajos de *success rate* llega un momento que deduce que es más probable ir en una dirección diferente, lo cual no sucede con valores medios ya que la probabilidad de resbalar es la misma que no hacerlo.

En adición, para el mapa 8x8 se produce el mismo efecto en el que los resultados presentan una gran variabilidad. Esto se debe nuevamente a que el método de estimación directa aprende únicamente a partir de episodios generados por experiencia.

Además, los mejores resultados suelen obtenerse con valores altos de gamma. Esto ocurre porque el agente da mayor importancia a las recompensas futuras, favoreciendo trayectorias largas orientadas a alcanzar la meta. Aunque para factores de descuento pequeños no hay mejoría en absoluto.

2.1.3. Experimento 3

Se ha planteado la siguiente hipótesis:

- **Relación con el factor de descuento:** esperamos que al aumentar el factor de descuento

aumente la tasa de éxito del agente.

- **Escalabilidad del tamaño:** el mapa 4x4 presenta mejores resultados que el mapa con tamaño 8x8.




Figura 8: Gráfico que relaciona el factor de descuento con la tasa de éxito del algoritmo de estimación directa.

Análisis de los resultados:

La figura 8 presenta la relación entre el factor de descuento y la tasa de éxito. De acuerdo con la gráfica, cuando $\gamma = 0$, la tasa de éxito es nula en ambos entornos. Esto ocurre porque el agente sólo evalúa recompensas inmediatas y, como la recompensa se obtiene al llegar al objetivo final, el agente no logra aprender trayectorias útiles.

Al incrementar el valor del factor de descuento a valores intermedios, entre 0.3 y 0.5, se observa una mejora considerable en el rendimiento del agente. En el mapa 4x4 la tasa de éxito alcanza valores cercanos al 27 %, mientras que en el entorno 8x8 el máximo obtenido se aproxima al 7 %. Este comportamiento se debe a que el agente comienza a considerar recompensas futuras y logra aprender rutas más efectivas para alcanzar el objetivo.

Además, los resultados del mapa 4x4 son significativamente mejores que en el entorno 8x8, ya que el mapa 4x4 posee menos estados y trayectorias más cortas, lo que facilita el aprendizaje del agente. Por otra parte, el entorno 8x8 incrementa la complejidad del problema, ya que hay un mayor número de acciones y aumenta la probabilidad de caer en estados no deseados, lo cual ralentiza la convergencia.

Finalmente, para valores altos de gamma, la tasa de éxito tiende a estabilizarse. En el caso del mapa 4x4 incluso hay una disminución del rendimiento. Esto muestra que otorgar demasiada importancia a recompensas futuras puede introducir mayor variabilidad en las estimaciones, lo que puede afectar a la estabilidad del aprendizaje.

2.1.4. Experimento 4

Se ha planteado la siguiente hipótesis:

- **Relación con la probabilidad de transición:** esperamos que al aumentar el factor de descuento aumente la tasa de éxito del agente.
- **Escalabilidad del tamaño:** el mapa 4x4 presenta mejores resultados que el mapa con tamaño 8x8.
- **Factor de descuento:** sucederá lo mismo que en el experimento 1.




Figura 9: Gráfico que relaciona la probabilidad de transición con el tiempo de entrenamiento del algoritmo de estimación directa.

Análisis de los resultados:

En la figura 9 se representa la relación entre la tasa de éxito y el tiempo total de entrenamiento. Muestra que el tiempo de entrenamiento tiende a incrementarse al aumentar la probabilidad de transición, o *success rate*, del agente. Esto ocurre porque valores más grandes de *success rate*, al existir mayor probabilidad de ejecutar correctamente las acciones, hacen que el agente consiga recorrer trayectorias más completas y alcanzar estados más lejanos del entorno. Como consecuencia, los episodios pueden durar más tiempo y el algoritmo requiere procesar una mayor cantidad de información durante el aprendizaje.

Esta gráfica es igual, o prácticamente igual, a la de la figura 6. Pensábamos que sería parecida, pero no tanto. En este método, el aprendizaje depende directamente de episodios completos, por lo que el tiempo total de entrenamiento está estrechamente relacionado con la cantidad de iteraciones o episodios necesarios para converger. En consecuencia, los cambios de parámetros como el factor de descuento o el *success rate* tienen los mismos efectos tanto en el tiempo de entrenamiento como en las iteraciones para converger, y además por los mismos motivos.

2.1.5. Experimento 5

Se ha planteado la siguiente hipótesis:

- **Relación señal de recompensa (objetivo):** esperamos que cuando aumente la señal de recompensa, la tasa de éxito se quedará constante.

- **Relación tiempo con tamaños de mapa:** el mapa de 8x8 debería tener tiempos de ejecución con un margen significativamente mayor al del mapa de tamaño 4x4 (64 y 16 casillas o celdas, respectivamente). Al haber más espacio por el cual moverse y más estados por los que iterar al hacer el *Value Iteration*, el tiempo de ejecución debería ser mayor.




Figura 10: Gráfico que relaciona la señal de recompensa con la tasa de éxito del algoritmo de estimación directa.

2.1.6. Experimento 6

Antes de realizar el experimento, se ha planteado la siguiente hipótesis:

- **Relación tiempo con la gamma:** esperamos que cuando la variable gamma del entorno aumenta, el tiempo total de entrenamiento se vea incrementado. La justificación es que, al ser la gamma mayor, se tienen más en cuenta los valores futuros y, por lo tanto, en cada iteración el valor de cada estado $V_{k+1}(s)$ varía más y cuesta más converger.
- **Relación tiempo con tamaños de mapa:** el mapa de 8x8 debería tener tiempos de ejecución con un margen significativamente mayor al del mapa de tamaño 4x4 (64 y 16 casillas o celdas, respectivamente). Al haber más espacio por el cual moverse y más estados por los que iterar al hacer el *Value Iteration*, el tiempo de ejecución debería ser mayor.




Figura 11: Gráfico que representa los tiempos medios de entrenamiento para cada tamaño de mapa según su factor de descuento con el algoritmo de estimación directa.

Análisis de los resultados:

Las hipótesis con la gamma se han cumplido ya que, como se puede observar, el tiempo de ejecución crece acorde al crecimiento de la gamma.

En cambio, con la hipótesis de los mapas nos hemos contradicho con el resultado, ya que el mapa 4x4 tiene tiempos de ejecución mucho más grandes que el de 8x8.

Primero de todo, estimación directa tiene dos partes. En la primera, el algoritmo juega tantas acciones como se estipule en el código y de estas acciones recoge resultados. En la segunda parte, con los resultados obtenidos se genera un modelo y se aplica el algoritmo *Value Iteration*; así se obtiene finalmente la política.

La justificación que se ha encontrado es que, por cómo está hecho el algoritmo, en la primera parte los dos tipos de mapa hacen la misma cantidad de iteraciones, por lo tanto deberían tener un tiempo muy similar. Por contra, en la segunda parte, nos encontramos con que debido a la complejidad de los mapas 8x8, hay más acciones que acaban en pozos de hielo, y el 4x4 al revés, tiene más probabilidad de llegar a la meta. Con esto se puede deducir que el mapa 4x4 tiene más información de todo el mapa; en cambio, el 8x8 tiene información más concentrada y mucha de la información es de los pozos de hielo. Por lo tanto, al hacer el *Value Iteration*, los mapas 8x8 convergen mucho antes, a diferencia de los 4x4, que tienen información más distribuida por todo el mapa.

3. Q-Learning

Este algoritmo aprende el valor de las acciones en cada estado mediante la interacción con el entorno, actualizando sus conocimientos paso a paso sin esperar al final del episodio.

Después de cada acción ejecutada, el algoritmo observa la recompensa inmediata y el siguiente estado, y actualiza su estimación de la calidad (valor Q) de la pareja estado-acción considerando la mejor opción futura posible.

El valor de una acción en un estado se estima mediante la ecuación de Bellman:

$$Q_{k+1}(s, a) = Q_k(s, a) + \alpha \left[r + \gamma \max_{a'} Q_k(s', a') - Q_k(s, a) \right]. \quad (3)$$

En contraste con la estimación directa, el Q-Learning no se ve obligado a completar cada episodio para aprender, lo que le otorga una mayor flexibilidad y eficiencia en tareas largas o continuas. La principal ventaja del Q-Learning es que se trata de un algoritmo *off-policy*, en el cual la política en la que se aprende puede diferir de la política de exploración aleatoria que se aplica. Sin embargo, el Q-Learning también tiene su precio, ya que requiere mantener un complicado equilibrio entre exploración y explotación, e incluso puede perder estabilidad si los parámetros de aprendizaje no están bien ajustados.

3.1. Análisis

3.1.1. Experimento 1

Antes de realizar el experimento, se ha planteado la siguiente hipótesis:

- **Relación con la estocasticidad:** esperamos que a medida que la variable *Success Rate* del entorno aumente (el suelo resbala en mayor cantidad), la tasa de éxito se vea disminuida por consecuencia directa.
- **Escalabilidad del tamaño:** el mapa 4x4 debería presentar resultados superiores al mapa con tamaño 8x8 (16 y 64 casillas). Es más probable encontrar la meta mediante la exploración inicial (epsilon, ϵ).
- **Inestabilidad:** debido a la naturaleza del algoritmo Q-Learning (basado en ensayo y error), prevemos una alta varianza en los resultados entre diferentes ejecuciones.




Figura 12: Gráfico que refleja la relación directa entre la variable *Success Rate* y la tasa de éxito.

Análisis de los resultados:

Los resultados de la ejecución del experimento del agente indican claramente que el mapa de 4x4 presenta una ventaja al ser capaz de obtener una política efectiva gracias a una mayor manejabilidad en los espacios de estados, mientras que el mapa de 8x8 se encuentra con una especie de muro de rendimiento cercano al 0 % como consecuencia del problema de las *sparse rewards* (el agente no recibe ningún premio ni castigo mientras explora el espacio de estados) y, por tanto, es mucho más difícil que el agente obtenga la recompensa que necesita para actualizar su tabla Q.

Esta alta varianza, así como la dependencia de la suerte en los primeros episodios del aprendizaje, pone de manifiesto las limitaciones del Q-Learning en entornos de gran tamaño o con fuerte aleatoriedad. La dificultad del problema (parámetro *slippery*) fue inversamente proporcional al aprendizaje del agente. La tendencia general indica que el algoritmo es mucho más eficiente en entornos deterministas que cumplen estrictamente las acciones del agente.

En conclusión, para estabilizar el entrenamiento del agente de manera que pueda aprender para mapas de mayores dimensiones se sugiere implementar mejoras como el uso de un *Wrapper* que sea capaz de guiar mejor la señal de recompensa o también la aplicación de técnicas para la decaída del factor de exploración epsilon o la tasa de aprendizaje.

3.1.2. Experimento 2

Antes de realizar el experimento, se ha planteado la siguiente hipótesis:

- **Relación con la supervivencia:** esperamos que cuando la variable *Success Rate* del entorno aumenta (el suelo resbala menos y el agente tiene más control sobre los pasos), el tiempo total de entrenamiento se vea incrementado. Como el agente cae menos a los pozos, da más pasos por episodio, lo que obliga al ordenador a realizar más cálculos.
- **Escalabilidad a lo largo de los diferentes tamaños de mapa:** el mapa de 8x8 debería tener tiempos de ejecución con un margen significativamente mayor al del mapa de tamaño 4x4 (64 y 16 casillas o celdas, respectivamente). Al haber más espacio por el cual moverse, la carga computacional para la CPU será superior.
- **Neutralidad de los hiperparámetros:** dado el carácter matemático del algoritmo, se prevé que la modificación del *Learning Rate* no afecte al tiempo físico de reloj, pues el coste para procesar la ecuación de actualización permanece constante sin importar el multiplicador empleado.




Figura 13: Tiempo total de entrenamiento de Q-Learning frente al *success rate*.

Análisis de los resultados:

Los tiempos de entrenamiento dejan en evidencia una diferencia estructural extrema para ambos mapas. El mapa 4x4, al tener tiempos muy bajos (en torno a los 0.5 s) y prácticamente estables debido a que la brevedad de los trayectos hace que la CPU no aprecie diferencias importantes, contrasta con un mapa 8x8 en el que los tiempos existentes son entre 3 y 5 veces más altos, dejando claro que la escalabilidad del mapa es el principal factor que consume recursos.

En el caso de esta versión mayor se puede observar un aumento del tiempo en relación a la supervivencia del agente, que queda reflejada en una pendiente ascendente en relación al incremento del *Success Rate*. Esto significa que cuando no resbala el hielo el agente no muere en los pozos y puede pasear por un número mayor de casillas, lo que ordena largas secuencias y hace que el ordenador tenga que aplicar el algoritmo de actualización un número mucho mayor de veces.

Por último, la total indiferencia que muestra el *Learning Rate* con las líneas de colores superpuestas y entrelazadas que vemos en la gráfica aclara que la velocidad física del entrenamiento depende de la dinámica del juego (del número de pasos que puede realizar el agente antes de detener el episodio) y no de la realización del ejercicio de cálculos numéricos o del ajuste de celdas en su tabla Q.

3.1.3. Experimento 3

Se ha planteado la siguiente hipótesis:

- **Relación con la visión de largo plazo (γ):** nuestra hipótesis establece que a medida que la variable Gamma aumente, la tasa de éxito debería mejorar enormemente. Un Gamma de 0 lleva al agente a un estado de miopía únicamente interesado en recompensas inmediatas, lo que produciría un completo desastre en un entorno donde la recompensa solamente se encuentra al final del mapa.
- **Escalabilidad del tamaño:** estimamos que en el mapa 8x8, aun ajustando un Gamma óptimo (típico 1), el agente tendrá grandes problemas en aprender, ya que el factor de

descuento no resuelve el problema de tener que buscar la meta pura y elementalmente a raíz de la suerte inicial.




Figura 14: Impacto de Gamma en la tasa de éxito.

Análisis de los resultados:

En la gráfica se observa que, cuando $\gamma = 0$, la tasa de éxito es prácticamente nula en ambos entornos. Esto ocurre, como hemos mencionado en la hipótesis, porque el agente únicamente considera recompensas inmediatas y no logra asociar las acciones actuales con la recompensa final obtenida al alcanzar la meta.

Al aumentar el valor del factor de descuento, la tasa de éxito mejora considerablemente, especialmente en el entorno 4x4. En contraste, el entorno 8x8 presenta tasas de éxito mucho menores para todos los valores de Gamma analizados, hecho que se podía deducir al ver el comportamiento de los mismos experimentos con algoritmos diferentes. Aunque existe una ligera mejora al incrementar Gamma, el rendimiento máximo se mantiene cercano al 6 %. Esto puede explicarse por la mayor complejidad del entorno, ya que el mapa 8x8 contiene un número más elevado de estados y trayectorias posibles.

3.1.4. Experimento 4

En la función de recompensa incentivada le hemos dado estos valores:

- **Meta = 1:** mantenemos el valor.
- **Pozo = -0.5:** inicialmente se había pensado ponerle -1.0, pero experimentando nos hemos dado cuenta de que no tenía ningún sentido, ya que le dábamos el mismo valor pero en negativo que a la meta, haciendo así que el agente no arriesgase nunca.
- **Paso = -0.001:** se le ha dado este valor para que tampoco reste tanto como el pozo de hielo y, a su vez, tampoco reste demasiado. Con esto intentamos que el agente no decida ir dando vueltas sin ir hacia el objetivo.

A partir de esto, nuestra hipótesis antes de hacer el experimento fue:

- **Incentivada vs normal:** se espera que la incentivada tenga una mayor tasa de éxito que la normal debido a que está mejor orientada.




Figura 15: Comparación de tasa de éxito entre recompensa normal e incentivada.

Análisis de los resultados:

En la gráfica se puede observar que nuestra hipótesis es errónea porque en ambas gráficas las tasas de éxito no tienen una diferencia significativa entre sí como para afirmar que es correcta.




Figura 16: Tiempo total de entrenamiento de Q-Learning frente al *success rate*.

4. Conclusiones

En esta práctica hemos estudiado cómo funcionan tres algoritmos de aprendizaje por refuerzo: Iteración por valor, Estimación directa y Q-Learning. Estos algoritmos se han evaluado en distintas condiciones de estocasticidad y escala del entorno, y los resultados alcanzados nos permiten llegar a las siguientes conclusiones generales.

Acerca del papel que juega el modelo, se puede observar que la diferencia más determinante entre los tres algoritmos no es la función que realiza cada uno en condiciones favorables del entorno, sino el comportamiento que tienen dichos algoritmos cuando el entorno se complica. Para Iteración por valor, que tiene acceso de manera previa al modelo MDP, es capaz de producir sistemáticamente la política óptima sin tener en cuenta el tamaño del mapa y el grado de estocasticidad, y lo realiza en tiempos de entrenamiento muy bajos (del orden de milisegundos). Estimación Directa y Q-Learning, al tener que aprender sin poder acceder al modelo, son mucho más sensibles a la variabilidad del entorno que el algoritmo Iteración por valor comentado anteriormente. Estos dos algoritmos necesitan un gran número de episodios para aproximar políticas razonables, especialmente en el caso de un mapa de mayor tamaño (8x8).

4.1. Efecto del *success rate*

Una de las conclusiones más clave y en común a los tres algoritmos es el comportamiento no monótono de este parámetro. En vez de una relación lineal en aumento, los tres algoritmos muestran un patrón en forma de U respecto a la tasa de éxito.

La explicación es la misma en todos los casos: los valores de *success rate* bajos hacen que el agente aprenda a explotar las transiciones laterales como parte de su estrategia de aprendizaje. Es decir, adopta una política conservativa funcional.

Los valores de *success rate* intermedios implican un entorno del tipo más incontrolable, ya que la probabilidad de ir en la dirección deseada y la probabilidad de resbalar son similares, lo que desestabiliza el aprendizaje en los tres algoritmos. Este resultado, que no nos habíamos planteado en nuestras hipótesis iniciales, aparece de manera reproducible en Iteración por Valor, Estimación directa y Q-Learning, lo que nos podría hacer pensar que es una propiedad estructural del entorno FrozenLake y no un artefacto de ningún algoritmo en particular.

4.2. Efecto del factor de descuento (γ)

Los experimentos han demostrado que la gamma es uno de los factores más relevantes. A medida que gamma crece, el rendimiento cambia de forma clara, aunque hay diferencias notables entre mapas: en el 4x4, las tasas de éxito son ya aceptables a valores intermedios, mientras que en el 8x8 los valores altos (0.8–0.95) son necesarios para obtener tasas de éxito considerables. Esto aprueba la teoría porque, cuanto más largo es el camino hacia la recompensa, más necesario resulta que el agente valore el futuro.

4.3. Efecto sobre la escalabilidad al mapa 8x8

Para el algoritmo Iteración de Valor, el coste es principalmente computacional: más estados implica más tiempo de cómputo, pero la calidad de la política no tiene por qué verse afectada. Para los algoritmos Estimación directa y Q-Learning, en cambio, la degradación es en calidad, por lo que un espacio de estados tan grande hace que la exploración aleatoria sea enormemente ineficaz, y se deteriora el problema de las *sparse rewards* porque la probabilidad de llegar al *goal*

en episodios tempranos es casi nula.

Esto es algo que reflejan los resultados para el algoritmo Q-Learning, que se queda en el 8x8 atascado en un 0 % de probabilidades de éxito salvo que se aumenten los episodios de entrenamiento y se ajuste muy cuidadosamente el *decay* de epsilon.

4.4. Efecto sobre la función de recompensa

Los experimentos sobre la función de recompensa de tipo incentivada muestran que no es una medida universal. En el mapa 4x4 con *success rate* alta, la recompensa por defecto produce resultados iguales o mejores, puesto que el agente ya tiene suficiente señal para aprender. La penalización de pozo tiende a hacer al agente demasiado conservador en contextos donde asumir cierto riesgo es necesario para llegar al *goal*.

En contrapartida, en el mapa 8x8 con *success rate* alta, la función incentivada sí mejora la tasa de éxito, dado que la señal auxiliar de pozo ayuda a propagar valor en un espacio de estados donde la recompensa del *goal* tarda mucho en llegar a los estados iniciales. En resumen, la conclusión práctica es que la función de recompensa debe ser diseñada en relación con la complejidad del entorno: no existe una configuración universalmente mejor.

4.5. Efecto sobre el tiempo de entrenamiento

Los tiempos de entrenamiento ponen de manifiesto las diferencias que existen entre algoritmos, al mostrar de forma intensificada las diferencias estructurales existentes.

La convergencia de Iteración de Valor está en tiempos del orden de milisegundos, mostrándose predecible su dependencia del tamaño del mapa y de gamma, aunque quizás debamos esperar tiempos del orden de segundos. Por su parte, Q-Learning tiene tiempos del orden de 5–30 segundos, dependiendo de los episodios a ejecutar, de sus tamaños y del *success rate*, siendo el factor más influyente el tamaño de la duración media de los episodios (que aumenta en el caso de *success rates* altos, ya que el agente puede sobrevivir más tiempo).

Estimación directa es la que presenta tiempos de entrenamiento más altos y más variables, especialmente en el caso del mapa 4x4, donde la duración de Iteración por valor sobre el modelo estimado puede tardar más que en el 8x8 por motivos de cobertura del espacio de estados. A nivel de eficiencia (ratio rendimiento/tiempo), Iteración por valor es imbatible cuando tenemos el modelo, y Q-Learning es la opción más razonable cuando no tenemos el modelo.

4.6. Conclusión final

Si el objetivo está puesto en maximizar la tasa de éxito y se tiene el modelo del entorno, indudablemente la Iteración por valor es la opción más acertada de las que disponemos en todos los escenarios. Si no existe el modelo de entorno, la elección más robusta de todas, especialmente si el entorno tiene gran tamaño (grandes mapas), es Q-Learning con gamma alta (≥ 0.95), *epsilon decay* lenta y número suficiente de episodios.

La Estimación directa, en la forma en que lo hemos implementado con exploración uniforme, no tiene ventajas en relación con Q-Learning en ninguno de los escenarios probados: al contrario, vemos que tiene peor resultado y el tiempo de entrenamiento es mayor y mucho más impredecible. Para los entornos en los que la complejidad empieza a ser elevada (superior a 8x8), cualquiera de los tres algoritmos de los que hablamos no escala bien sin que hagamos un uso intensivo de los algoritmos que hemos mencionado en el apartado de antecedentes, como podrían ser los gradientes de política o la aproximación de las funciones de valor.